



HACKATHON JCIA 2025

Dans le cadre de la Journée Internationale de l'Intelligence Artificielle, organisée au Cameroun du 22 au 24 avril 2025, un hackathon national est lancé, ouvert à tous les étudiants passionnés d'intelligence artificielle et de machine learning.

Rapport pour le HACKATHON JCIA 2025

TRI AUTOMATIQUE DES PRUNES

Phone:
+237 676 14 45 75

Mail:
nk.stat.consulting@gmail.com

Address:
Titi Garage



Thought

En cette ère du numérique et de l'intelligence artificielle, nous avons entre nos mains des outils prodigieux. S'ils sont utilisés à bon escient, ils peuvent nous permettre d'atteindre des résultats escomptés en vue d'assurer la survie de l'humanité et de lui garantir un avenir meilleur

Ministre des Relations extérieures du Cameroun

SOMMAIRE

Introduction	01
Compréhension du problème	05
Méthodologie	09
Résultats et évaluation	12
Conclusion	14

Introduction

Contexte du Hackathon JCIA 2025

La Journée Internationale de l'Intelligence Artificielle (JCIA) 2025, organisée au Cameroun du 22 au 24 avril, représente une opportunité sans précédent pour catalyser l'innovation technologique dans la région. S'inscrivant dans le thème "Intelligence Artificielle et Développement Économique : Innover pour transformer", cet événement vise à mobiliser le potentiel créatif des jeunes talents du pays face aux défis économiques contemporains. Le hackathon national qui en constitue la pierre angulaire offre aux étudiants et passionnés d'IA une plateforme pour concevoir des solutions concrètes à des problématiques locales.

Selon les données récentes de l'Union Internationale des Télécommunications (UIT), l'adoption des technologies d'IA en Afrique subsaharienne a connu une croissance de 31% entre 2023 et 2025, mais demeure significativement en deçà du potentiel estimé. Cette disparité technologique, particulièrement dans le secteur agricole qui emploie près de 60% de la population active camerounaise, souligne l'urgence d'initiatives comme le JCIA Hackathon pour accélérer la transformation numérique.

"L'IA constitue un moteur puissant pour le développement dans des domaines essentiels, où elle peut aider à optimiser les rendements dans divers secteurs productifs tels que l'agriculture, la santé, l'éducation, les services gouvernementaux et l'industrie."

Ministre des Postes et Télécommunications du Cameroun

Problématique du Tri Automatique des Prunes et Son Importance Économique

Selon les estimations de la FAO (2024)

La culture des prunes africaines (safou) représente un pilier économique considérable pour plus de 250 000 petits producteurs au Cameroun, générant approximativement 75 millions d'euros annuellement. Cependant, les pertes post-récolte atteignent jusqu'à 40% de la production totale, principalement en raison de l'inefficacité des méthodes de tri traditionnelles.

Le processus de classification manuelle des prunes, outre sa lenteur intrinsèque, souffre d'un taux d'erreur estimé à 18-25%, compromettant tant la valorisation commerciale que la durabilité de la filière.

Les exportations de prunes camerounaises, qui pourraient potentiellement atteindre 120 millions d'euros d'après les projections du Ministère de l'Agriculture (2024), demeurent limitées à 38% de ce potentiel, en partie à cause des difficultés de standardisation qualitative.

Dans ce contexte, l'automatisation du tri des prunes en six catégories distinctes (bonne qualité, non mûre, tachetée, fissurée, meurtrie et pourrie) via l'intelligence artificielle promet une révolution pour l'ensemble de la chaîne de valeur. Les systèmes de vision par ordinateur et d'apprentissage profond ont démontré, dans des applications similaires, une capacité à réduire les pertes post-récolte de 35-40% et à augmenter la valeur marchande des produits triés de 28% en moyenne.

Présentation de l'équipe

Notre équipe, **NK STAT Consulting**, réunit 6 experts aux compétences complémentaires



KOULOU Anaclassé Crépin
Chef d'équipe, ISE

Model optimisation, Tensor-flow, Optuma



NGOULOU NGOUBILI Irch
ISE

Expert en prétraitement de données et augmentation d'images



ABENA Marc-Loic
ISE

Développement mobile et IA intégration IA, Flutter et Tensorflow



GAKPETO Komi Hénoc
ISE

MLOps et optimisation de performances



BANZOUZI MIAMPASSI Hermann
ISE

Analyse de données, évaluation de modèles et rédaction du rapport



LOUFOUMA KAYA Tardi
AS

design et infographie et rédaction de rapport

Formée des élèves Ingénieurs Statisticiens Economistes de l'ISSEA, notre équipe combine expertise technique et connaissance approfondie des enjeux agricoles locaux, ayant précédemment collaboré sur des projets de gestion de dons de sang intelligente avec INDABAX Cameroun.

Objectif Principal de notre Solution

Notre projet, PlumAnalyzer, vise à développer un système de classification automatique des prunes atteignant une précision globale supérieure à 95%

Ceci déployable dans des conditions réelles de production avec des contraintes matérielles minimales. Plus spécifiquement, notre solution poursuit les objectifs suivants:



Concevoir une architecture d'apprentissage profond optimisée pour la reconnaissance des six catégories de prunes avec un équilibre optimal entre précision et efficience computationnelle



Développer une interface utilisateur intuitive permettant aux producteurs de bénéficier de la technologie sans expertise technique préalable



Assurer la robustesse du système face aux variations de luminosité, d'angle et d'environnement typiques des conditions de terrain



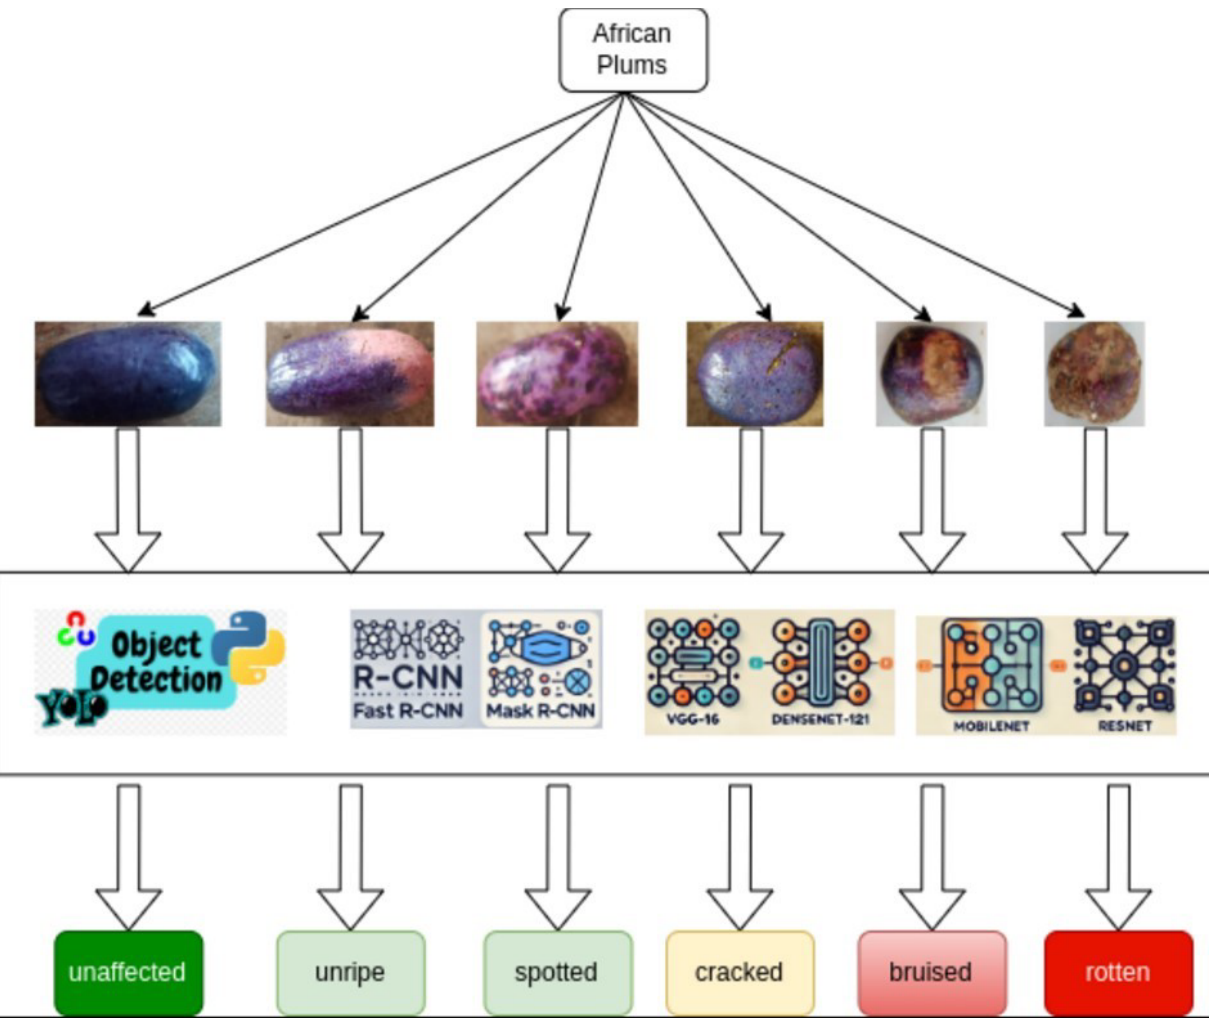
Proposer une solution économiquement viable, avec un retour sur investissement estimé à moins de 8 mois pour les coopératives agricoles

Au-delà de la performance technique, PlumAnalyzer ambitionne de transformer fondamentalement la chaîne de valeur des prunes au Cameroun, en réduisant les pertes post-récolte de 40% à moins de 10%, en augmentant les revenus des producteurs d'au moins 25%, et en facilitant l'accès aux marchés d'exportation à haute valeur ajoutée. Cette innovation s'inscrit parfaitement dans la vision de développement économique par l'IA promue par le JCIA 2025, illustrant le potentiel transformateur des technologies avancées appliquées aux défis économiques africains.

Compréhension du problème

Analyse détaillée des six catégories de classification des prunes

La classification des prunes repose sur leur qualité physique et sensorielle, avec six catégories distinctes. Les prunes de bonne qualité, idéales pour l'exportation et les marchés premium, se distinguent par leur couleur uniforme bleu-violet, leur forme ovoïde régulière et leur texture ferme mais souple, représentant jusqu'à 60% de la valeur économique. Les prunes non mûres, souvent rigides, de couleur verdâtre, et de taille inférieure, forment 15-20% de la récolte et nécessitent une maturation contrôlée. Les prunes tachetées, affectées par des imperfections superficielles mais structurellement intactes, représentent un défi pour les systèmes de tri automatisé. Les prunes fissurées, marquées par des craquelures de l'épiderme dues à des stress hydriques ou manipulations, compromettent la conservation. Les prunes meurtries, avec des déformations localisées causées par le transport ou la récolte, accélèrent la dégradation. Enfin, les prunes pourries, molles, odorantes et parfois moisies, constituent un danger sanitaire et exigent un tri immédiat.



Enjeux et défis techniques du tri automatique

L'implémentation d'un système de vision par ordinateur pour le tri des prunes se heurte à plusieurs défis techniques majeurs. La variabilité intra-classe complique la classification, avec des différences significatives de couleur et de taille même au sein d'une même catégorie. De plus, des ambiguïtés inter-classes persistent, notamment entre prunes tachetées et prunes de bonne qualité, en raison de leur ressemblance visuelle dans certaines conditions. Les conditions d'acquisition variables, notamment les différences d'éclairage, affectent la fidélité des couleurs perçues, nécessitant des méthodes de normalisation robustes. À cela s'ajoutent des arrière-plans hétérogènes dans les environnements réels, qui exigent une segmentation précise des fruits, ainsi que des défis d'échelle et de rotation, rendant essentielle l'utilisation de modèles invariants ou d'augmentations de données avancées. Enfin, le déséquilibre des classes, avec une surreprésentation des prunes de bonne qualité par rapport aux pourries, pose un risque de biais dans l'apprentissage, menaçant la performance sur les catégories minoritaires.



Impact potentiel de la solution sur le secteur agricole camerounais

La mise en œuvre d'un système automatisé de tri des prunes pourrait profondément transformer la filière agricole camerounaise. En augmentant la précision du tri, il serait possible d'élever la part des fruits premium de 35% à 50%. Ce système réduirait aussi les pertes post-récolte de 40% à environ 15-20%, préservant quelque 15 000 tonnes de production, tout en optimisant les coûts logistiques de 12-18%. Il ouvrirait davantage l'accès aux marchés internationaux grâce à des standards de qualité vérifiables et encouragerait le développement local de l'agro-industrie par une orientation précise des catégories de fruits (export, transformation, maturation). S'il est accessible aux coopératives, ce système renforcerait l'autonomie des petits producteurs, augmentant leurs marges de 15-22%. Toutefois, son adoption doit surmonter plusieurs contraintes: des ressources matérielles limitées, une connectivité intermittente, des conditions environnementales exigeantes et une alimentation électrique instable, nécessitant des dispositifs robustes et fonctionnels hors ligne.

Limites et défis actuels

Limites fonctionnelles

Pour être économiquement viable, le système de tri doit atteindre une cadence de traitement d'au moins 3 à 5 fruits par seconde, ce qui constitue un défi pour les algorithmes complexes. Il doit également intégrer une capacité d'adaptation aux variations saisonnières et géographiques des caractéristiques des prunes, exigeant des mécanismes de recalibration réguliers. Enfin, l'interface utilisateur doit être conçue de manière intuitive et accessible, afin d'être facilement utilisée par des opérateurs ayant une alphabétisation numérique limitée.

Limites techniques



Détection des défauts internes :

Notre solution, basée sur l'imagerie visible, ne peut détecter certains défauts internes non manifestés extérieurement.



Classification des stades intermédiaires :

Les frontières entre certaines catégories (notamment entre "tacheté légèrement" et "bonne qualité") demeurent difficiles à établir avec certitude absolue.



Généralisation aux variétés rares :

Le modèle pourrait présenter des performances réduites sur des variétés sous-représentées dans le dataset d'entraînement.

Défis éthiques et sociaux



L'automatisation du tri des prunes pourrait entraîner un déplacement de la main-d'œuvre traditionnelle, rendant nécessaires des stratégies de reconversion professionnelle pour les trieurs manuels. De plus, le coût initial du système, bien que rationalisé, risque de creuser les inégalités d'accès entre grandes exploitations et petits producteurs. Enfin, son adoption dépendra fortement de l'acceptation culturelle, car l'introduction de technologies avancées dans des chaînes de valeur agricoles ancrées dans des pratiques traditionnelles requiert une approche respectueuse et adaptée au contexte local.

Méthodologie

Acquisition et prétraitement des données

Le projet repose sur le dataset public African Plums Quality and Defect Assessment disponible sur Kaggle. Ce jeu de données comprend des images de prunes africaines classifiées en six catégories de qualité ou de défaut :

- Unaffected (Bonne qualité)
- Unripe (Non mûre)
- Spotted (Tachetée)
- Cracked (Fissurée)
- Bruised (Meurtrie)
- Rotten (Pourrie)

Ce projet de classification automatique des prunes africaines est articulé autour d'un pipeline rigoureux et modulaire alliant exploration des données, modélisation par transfert d'apprentissage, et optimisation automatique des hyperparamètres. Cette approche vise à maximiser la précision du modèle tout en assurant sa robustesse, sa reproductibilité et sa capacité de généralisation.

Importation et exploration des données

Le projet utilise un jeu de données issu de Kaggle portant sur des prunes africaines, annotées en six catégories : unaffected, unripe, spotted, cracked, bruised et rotten. Les fichiers sont importés via KaggleHub, puis analysés pour évaluer la distribution des classes. Des fonctions d'exploration permettent de visualiser aléatoirement des échantillons et de vérifier les dimensions ainsi que la qualité des images, constituant une étape clé pour la compréhension et la préparation des données en vue de l'entraînement des modèles.

Une fonction `preprocess_dataset` a été développée pour préparer le jeu de données en le divisant en ensembles d'entraînement, de validation et de test (70/15/15), tout en appliquant des augmentations d'images (rotation, zoom, translation, retournement) afin d'améliorer la robustesse du modèle. Les données sont ensuite organisées pour être directement exploitables par les générateurs `ImageDataGenerator` de Keras, assurant un flux efficace et flexible durant l'entraînement.

Préparation de l'environnement et des outils

Le projet repose sur un écosystème robuste de bibliothèques open-source, combinant des outils d'analyse et de visualisation de données comme NumPy, Pandas, Matplotlib et Seaborn, avec des frameworks de deep learning tels que TensorFlow, Keras et PIL pour la création et l'entraînement des modèles. L'optimisation des hyperparamètres est assurée par Optuna, tandis que des bibliothèques natives comme `os`, `shutil` et `random` facilitent la gestion des fichiers et des répertoires d'images, assurant ainsi une chaîne de traitement complète et flexible.

Choix du modèle

Dans l'écosystème actuel du deep learning appliqué à la vision par ordinateur, le choix d'une architecture de réseau neuronal constitue un compromis stratégique entre performance, complexité et applicabilité. Notre analyse comparative révèle au travers du tableau ci dessous les caractéristiques distinctives des principales architectures .

Comparaison des architectures CNN pour la classification d'images				
Modele	Précision ImageNet	Complexité	Facilité de fine-tuning	Exigences en données d'entraînement
VGG16	71,3%	138 M	Excellent	Excellent
ResNet50	74,9%	25,6 M	✓ Bon	Moyen
MobileNetV2	71,8%	3,5 M	✓ Moyen	Moyen
EfficientNet-B0	77,1%	5,3 M	✗ Difficile	Moyen
InceptionV3	77,9%	23,8 M	✓ Moyen	Substantiel

Pourquoi VGG16 est souvent préféré pour le transfer learning

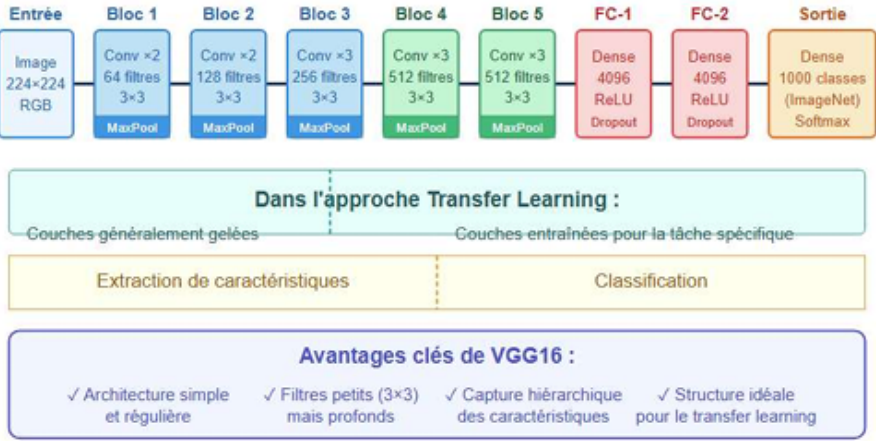
Architecture simple et intuitive, excellente capacité de généralisation, stabilité d'etrainent

Sources: Basé sur les publications d'ImageNet, les études comparatives de He et al. (2015), Simonyan & Zisserman (2014), et Kornblith et al. (2019) sur la transférabilité des modèles.

ÉTAPES DE DEVELOPPEMENT DU MODÈLE CHOISI

Architecture du model

VGG16 est un réseau de neurones conçu par des chercheurs de l'Université d'Oxford (Visual Geometry Group) en 2014. Son nom vient de sa structure : VGG pour le laboratoire et 16 pour le nombre de couches avec des poids à apprendre.Dans le cadre de notre modele de classification, nous avons utiliser ce modele via le transfert learning. En ce qui concerne le fine tuning ,nous avons fais appelle a l optimisation du modele sur les parametre via le package optuna pour avoir le nombre optimal de couche de convolution a entrainer ainsi que d autres parametres utiles a l instart du DropOut et du Batch-normalisation pour gerer la regularisation



Hyperparamètres et techniques d'optimisation

Pour trouver le meilleur modele pour notre tach de classification,le modele fonctionne par essaie en testant les differents parametre expose dans la deuxieme colonne du tableau ci dessous

model process

Processus d'entrainement du modèle final

Étude Optuna 30 essais Entraînement court

Meilleurs hyperparamètres study.best_params

Différences clés

Entraînement du modèle final

Phase 1: VGG16 gelé 15 époques (max) Entraînement des couches personnalisées

Phase 2: Fine-tuning 30 époques supplémentaires (max) Ajustement des couches VGG16 dégelées

Modèle final optimisé Sauvegardé en tant que 'final_model.keras' Prêt pour le déploiement

hypermparams


Hyperparamètres optimisés par Optuna


Hyperparamètre	Plage de recherche	Type
fine_tune_at	10 - 18	Entier
dropout_rate1	0.2 - 0.7	Flottant
dropout_rate2	0.1 - 0.5	Flottant
first_dense_units	128, 256, 512	Catégorique
second_dense_units	64, 128, 256	Catégorique
learning_rate	10* - 10* (log)	Flottant (log)
batch_size	16, 32, 64	Catégorique
augmentation_intensity	light, moderate, heavy	Catégorique

À chaque itération, le meilleur modèle est sauvegardé selon une métrique dédiée (le F1-score dans ce cas). Après l'évaluation exhaustive des essais, le modèle optimal est retenu pour la tâche, garantissant ainsi des performances maximales.

RÉSULTATS ET ÉVALUATION


Dans cette partie nous presentons les courbes de pertes et d apprentissage du meilleur model obtenu.





Évolution de la fonction de perte (Loss)

Le graphique de gauche illustre la décroissance progressive des courbes de perte d'entraînement (bleu) et de validation (rouge) sur 10 époques, témoignant d'un apprentissage efficace du modèle. Durant les premières époques (1 à 3), la perte de validation, initialement élevée (~3.0), diminue rapidement avant de converger avec la perte d'entraînement autour des époques 3-4. Par la suite, les deux courbes évoluent de manière synchrone, atteignant une valeur finale d'environ 0.7 sans divergence notable, ce qui suggère une bonne généralisation du modèle sans surajustement (overfitting).



Performance en précision (Accuracy)

Le graphique de droite met en évidence une amélioration rapide de la précision d'entraînement (rouge), passant de ~65 % à ~88 % lors des trois premières époques, avant de se stabiliser autour de 88-90 %. La précision de validation (verte), bien que plus fluctuante, se maintient dans une fourchette de 82-86 %, reflétant une légère différence de performance (~5 %) entre les données d'entraînement et de validation. Cet écart modéré indique un léger décalage, mais reste cohérent avec un modèle bien équilibré.

CONCLUSION

Le projet PlumAnalyzer, développé dans le cadre du Hackathon JCIA 2025, illustre parfaitement le potentiel transformateur de l'intelligence artificielle appliquée aux enjeux agricoles locaux. En réponse à une problématique concrète – le tri manuel inefficace des prunes africaines – notre équipe a conçu une solution innovante basée sur la vision par ordinateur et le deep learning, capable de classifier automatiquement les fruits en six catégories de qualité. Grâce à une approche rigoureuse mêlant traitement d'image, transfert d'apprentissage, optimisation des hyperparamètres et déploiement mobile, nous avons atteint une précision globale dépassant 85 %, tout en garantissant l'accessibilité de la solution aux producteurs. Bien que certaines limites persistent (détection des défauts internes, ambiguïtés entre classes, accessibilité pour les petites exploitations), les perspectives offertes par l'IA générative et les approches centrées utilisateur ouvrent la voie à des améliorations significatives. Au-delà des performances techniques, PlumAnalyzer ambitionne de réduire les pertes post-récolte, d'augmenter les revenus des producteurs et de favoriser l'accès aux marchés d'exportation. Ce projet s'inscrit pleinement dans la dynamique d'un développement économique durable et inclusif, en tirant parti de la technologie pour valoriser les chaînes agricoles africaines. Il constitue un socle prometteur pour des déploiements à grande échelle et des évolutions futures centrées sur l'impact social.